# Tema 6 – Escalabilidad

Tecnologías de los Sistemas de Información en la Red

# Índice

# Objetivos

- Conocer el compromiso entre consistencia, disponibilidad y tolerancia a las particiones de red cuando se utilicen servicios distribuidos.
- Identificarlos mecanismos básicos que permiten mejorar la escalabilidad de un sistema distribuido.
- Gestionar adecuadamente un sistema escalable para que sea elástico.
- Identificar las dificultades a vencer para implantar un sistema escalable: puntos de contención.

# Índice

# 1. Introducción

- El curso pasado, en CSD, se describieron varios mecanismos de escalado:
  - Distribución de procesos
  - Distribución de datos
  - Replicación
  - Uso de cachés
- Todos guardan relación con la consistencia de datos:
  - Cuanto más fuerte sea la consistencia mayor sincronización habrá entre los procesos.
    - Eso conduce a bloqueos. Por tanto, no es escalable.
  - La consistencia relajado no necesita intercambiar muchos mensajes
    - Puede ser escalable
    - Pero, en algunos casos, puede generar resultados inesperados.

# 1. Introducción

- Hay algunos aspectos de la consistencia que deben considerarse en los servicios escalables:
  - Teorema CAP
    - No se podrá utilizar una consistencia fuerte en un servicio altamente escalable.
  - Los modelos clásicos de replicación proporcionan consistencia fuerte (p.ej., secuencial)
    - Se necesitan otras aproximaciones para relajar la consistencia.
  - ¿Cómo podemos repartir los datos entre múltiples servidores?
    - Técnicas de particionado de datos ---> Almacenes NoSQL.

# Índice

# 2. Teorema CAP

- En un sistema distribuido no se puede mantener a la vez:
  - Una consistencia fuerte (C); p.ej., secuencial.
  - La disponibilidad de los servicios ("*Availability*": A).
    - Disponibilidad: Todo cliente obtiene respuesta siempre.
    - Cada réplica servidora puede tener sus clientes.
      - Todas los clientes deben ser capaces de obtener respuesta para considerar que el servicio está disponible.
  - La tolerancia al particionado de la red (P).
    - Que el fallo que se produzca sea en las comunicaciones y deje varios subgrupos sin posibilidad de intercomunicarse.
      - Pérdida de conectividad.
- Hay que sacrificar una de las tres propiedades.

# 2. Teorema CAP

- ¿Por qué se plantea este teorema?
  - En un sistema distribuido debe proporcionarse transparencia de fallos.
  - Para ello, hay que replicar todos los servicios proporcionados.
    - Así se asegura la DISPONIBILIDAD (A).
  - Debe proporcionarse la imagen de un sistema único.
    - Esto implica que los usuarios deben observar el mismo estado en todas las réplicas: CONSISTENCIA (C) secuencial.
  - La transparencia de fallos también obliga a que el sistema siga comportándose de igual manera aunque haya problemas de conectividad.
    - Esto fuerza a que se garantice la tolerancia al PARTICIONADO (P) de la red.

# 2. Teorema CAP

- Opción 1: Sacrificar la tolerancia al particionado de la red (P).
  - Cuando se quiera garantizar una consistencia fuerte y una disponibilidad total de los servicios, hay que renunciar a la tolerancia del particionado.
    - No se admitirá que la red se particione.
    - Habrá que garantizar (replicando la red, por ejemplo) la conectividad.
    - Pero eso es difícil de asegurar:
      - Solo se podría soportar en un despliegue local en un solo laboratorio
      - Incluso entonces sería extremadamente difícil de garantizar
        - ¡Hay que buscar otras alternativas!!

# 2. Teorema CAP

- Opción 2: Sacrificar la disponibilidad (A).
  - En este caso se pretende asegurar la consistencia fuerte y la tolerancia a las particiones.
  - Cuando haya una partición:
    - Se adoptará el modelo de partición primaria.
      - Todos los subgrupos minoritarios pararán.
        - Se perderá la disponibilidad en sus nodos.
        - Los clientes asociados a esos nodos podrán advertir esa situación.
      - Solo el subgrupo "primario" continuará
        - Sus nodos mantendrán una consistencia fuerte.
        - Es el subgrupo con una mayoría de nodos.

# 2. Teorema CAP

- Opción 3: Sacrificar la consistencia (C).
  - En este caso se pretende garantizar la disponibilidad de todas las réplicas correctas y la tolerancia al particionado de la red.
  - Cuando haya una partición:
    - Se admitirá que todos los subgrupos avancen.
      - Modelo particionable.
    - Al procesar escrituras en cada subgrupo, se perderá la consistencia fuerte.
      - Los demás subgrupos no pueden ver esas escrituras.
    - Si se diseña el sistema con cuidado y las operaciones son conmutativas, se podrá soportar una consistencia final.
      - Reconciliación de estado sencilla.

# 2. Teorema C AP

- ¿Cuál es la mejor opción?
  - Los servicios escalables deben estar siempre disponibles
    - Su objetivo es atender a un gran (y potencialmente creciente) número de usuarios
    - Una vez desplegados en múltiples centros de datos, podrán darse problemas de conectividad
      - Esas situaciones de particionado deben admitirse
    - Por tanto, debe sacrificarse la consistencia fuerte
      - De hecho, ese sacrificio no es una novedad pues ya es un requisito para ser altamente escalable

# Índice

# 3. Replicación multi-máster

- Hay dos modelos de replicación clásicos:
  - Pasivo (o replicación "primary/backup")
  - Activo (o replicación de máquina de estados)
- Infortunadamente, ambos son fuertemente consistentes
  - Esto limita su escalabilidad
- Hay una tercera solución:
  - Replicación multi-máster
    - Basada en el modelo pasivo, pero...
      - No hay una sola réplica primaria
      - Cada solicitud puede ser atendida por una sola réplica "master"
        - **¡Pero cada solicitud puede usar un máster distinto!**
      - La respuesta se envía de inmediato al cliente
      - Las modificaciones se envían de manera perezosa a las demás réplicas posteriormente

# 3. Replicación multi-máster

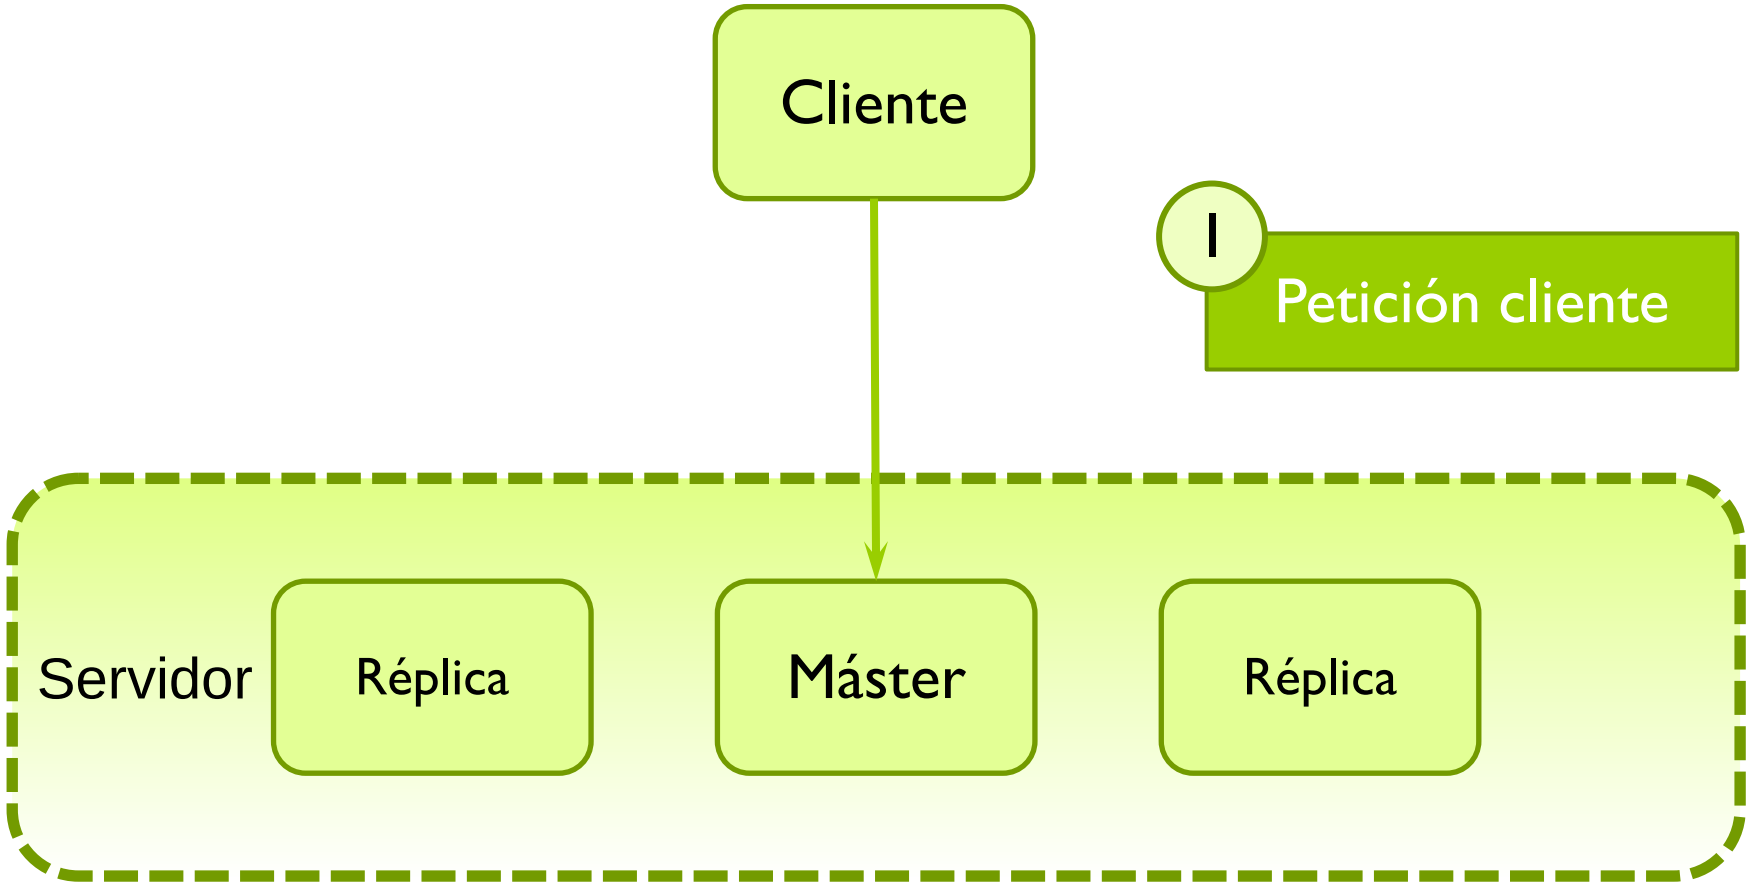

# 3. Replicación multi-máster

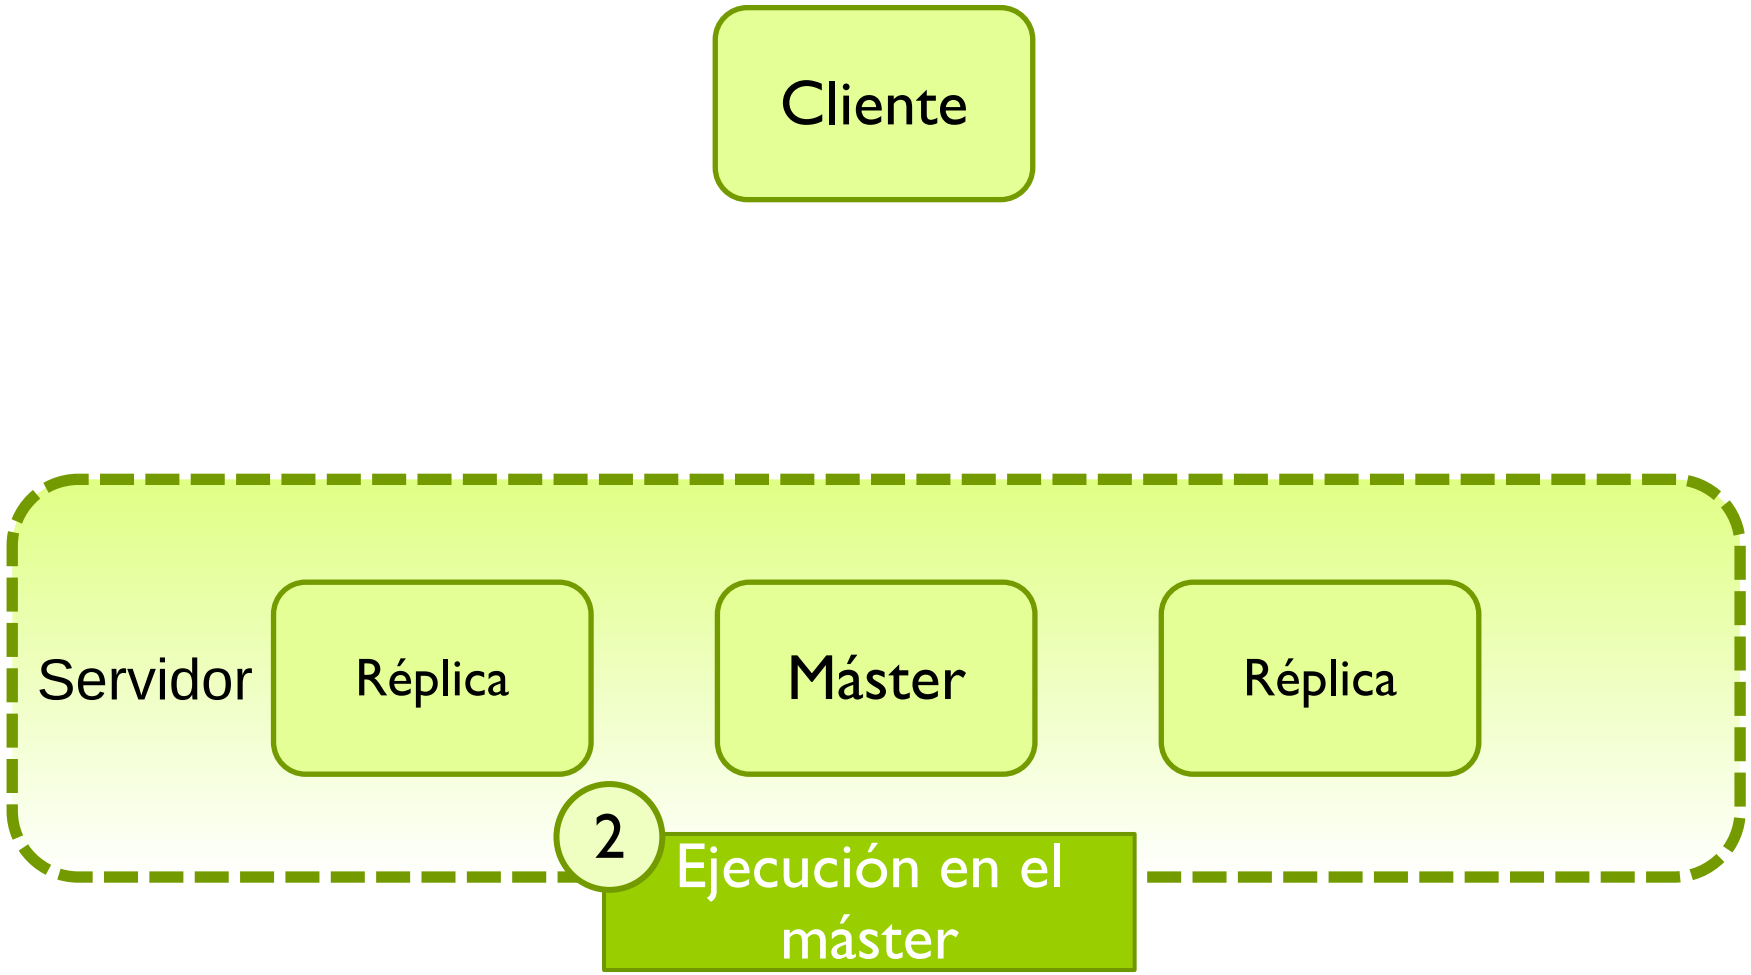

# 3. Replicación multi-máster

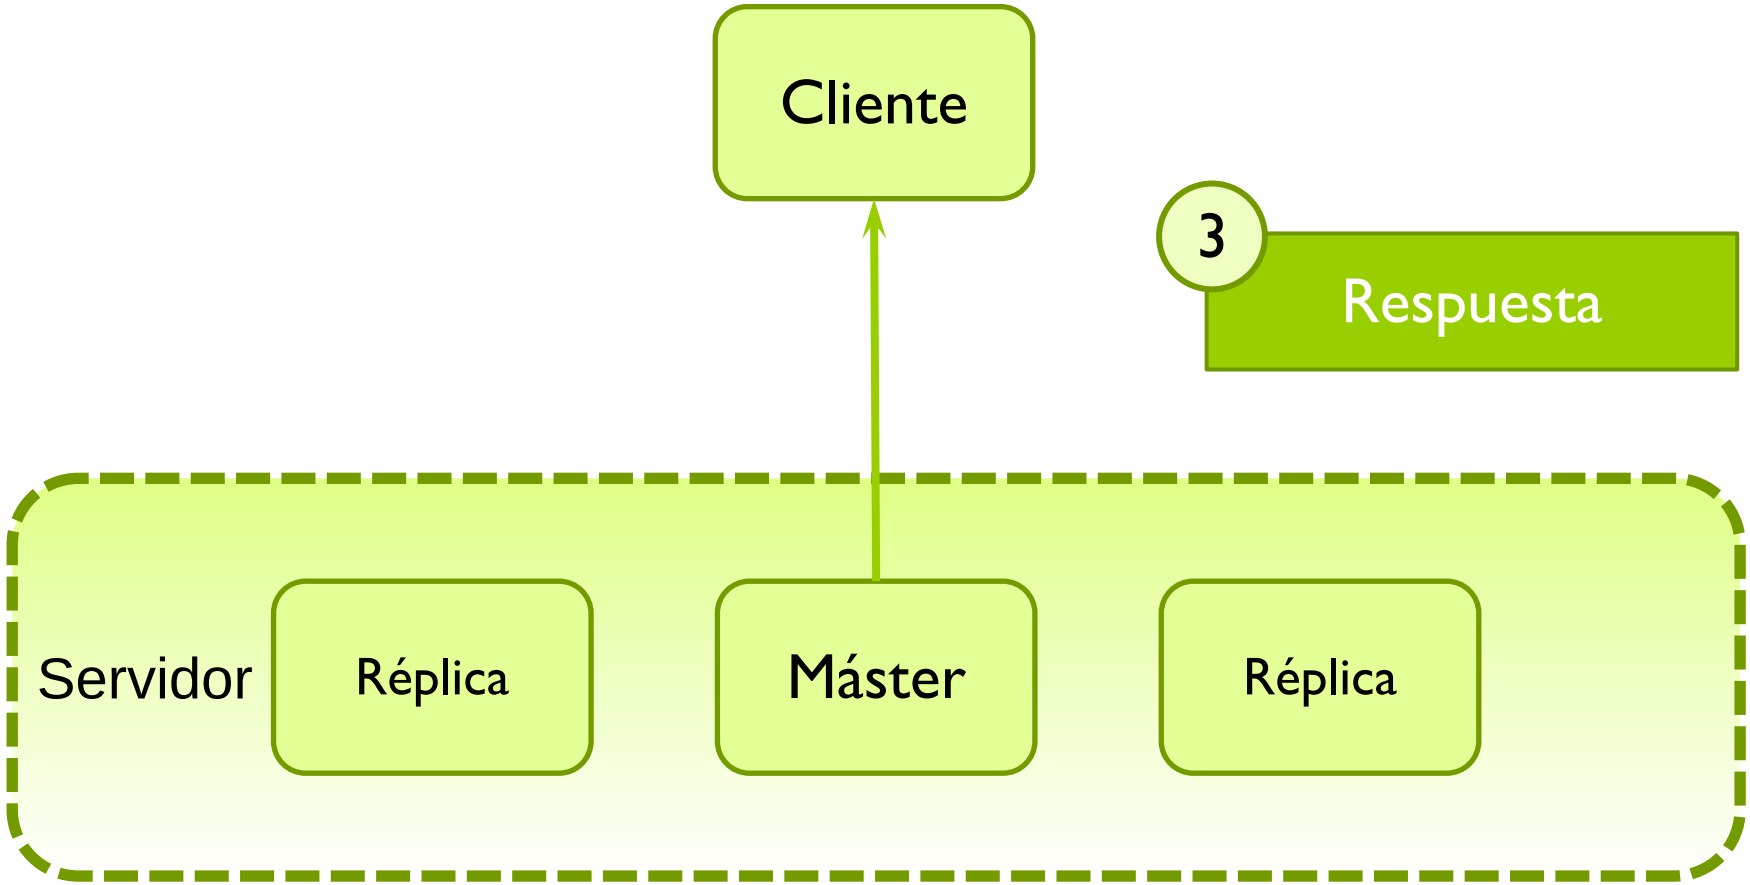

# 3. Replicación multi-máster

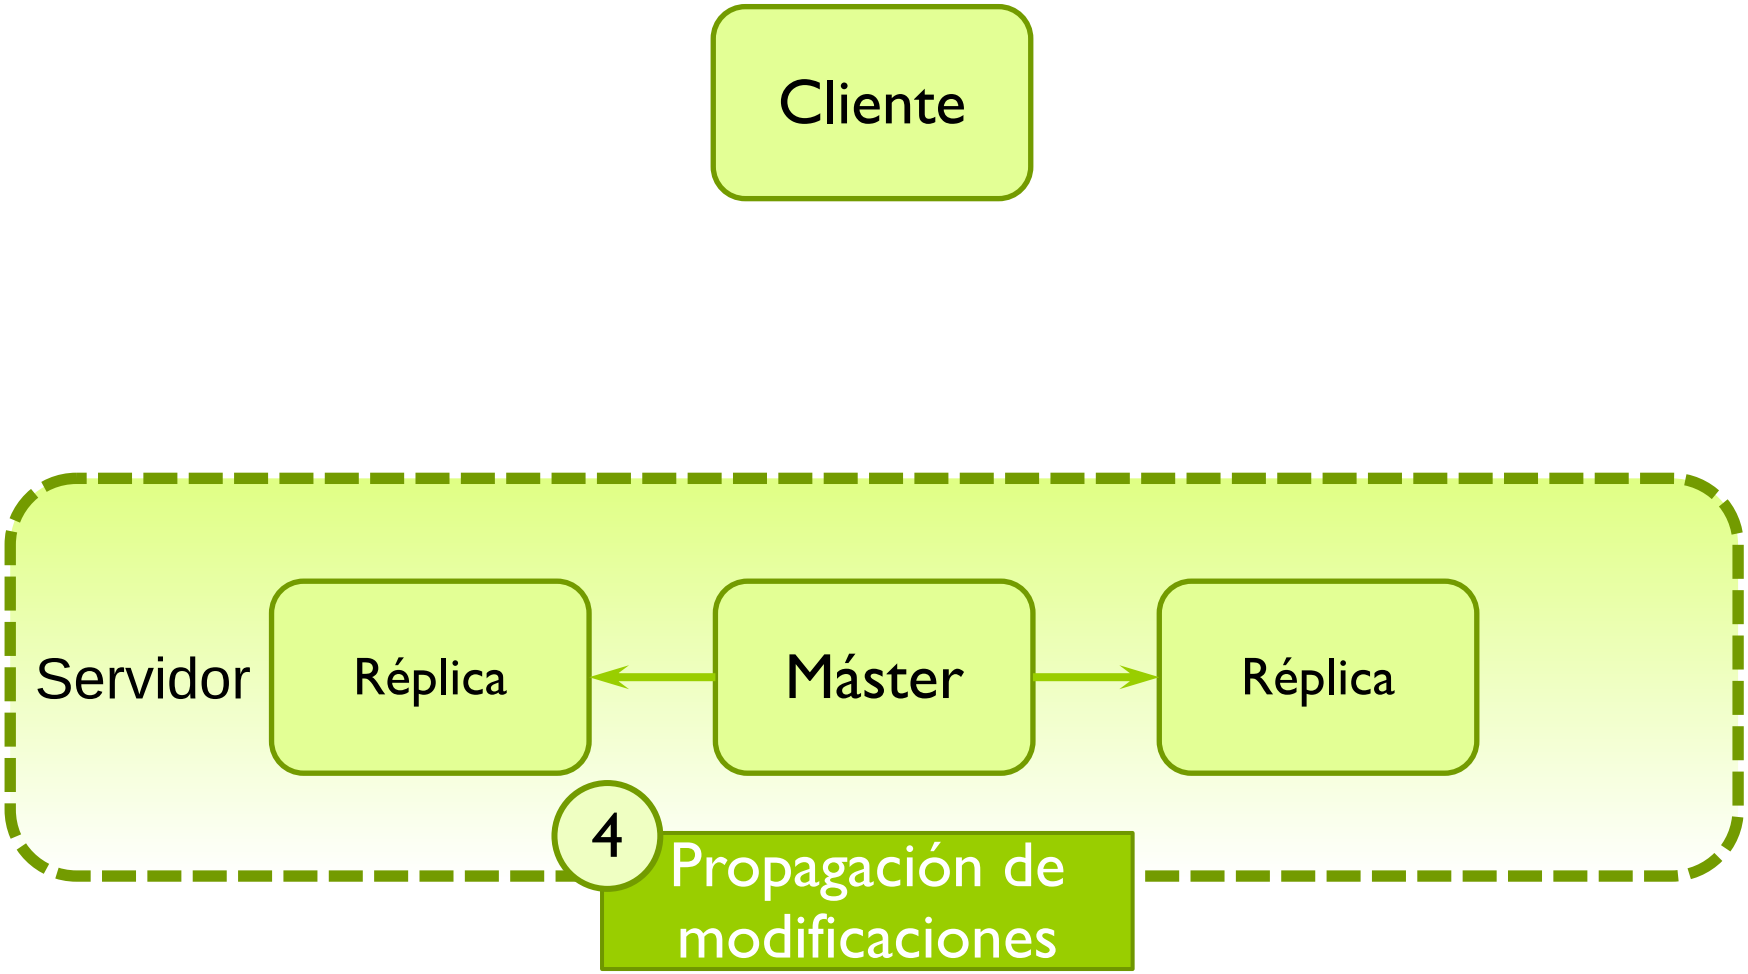

# 3. Replicación multi-máster

- Ventajas
  - Mínima sobrecarga
    - Cada petición es procesada por una sola réplica
      - Tanto para peticiones de solo lectura como de modificación
  - Altamente escalable
    - No asume ningún mecanismo de control de concurrencia
  - Admite operaciones no deterministas
    - Solo son ejecutadas por un máster
    - Nunca surgirán inconsistencias entre réplicas causadas por el servicio de una misma operación

# 3. Replicación multi-máster

- Inconvenientes
  - Problemas en caso de fallos
    - Sin un máster cae...
      - Sus peticiones en curso pueden perderse
  - Hereda la débil gestión de fallos del modelo pasivo
    - Los fallos arbitrarios no pueden gestionarse
  - Pueden surgir inconsistencias fácilmente
    - Entre operaciones concurrentes sobre un dato compartido atendidas por diferentes maestros
      - Esto puede resolverse si el programa fue escrito asumiendo consistencia final
      - ¡Pero es responsabilidad del programador!

# Índice

# 4. Almacenes NoSQL

- ¿Cómo mejorar la escalabilidad de una base de datos?
  - Simplificando el esquema
    - Sustituir múltiples tablas con múltiples columnas por tablas clave/valor.
      - Índices simples
    - Esto simplifica el lenguaje de interrogación
      - Procesamiento directo
    - El espacio ocupado por la base también se reduce
      - Las bases de datos pueden mantenerse en memoria principal
      - Persistencia asegurada mediante replicación
  - Eliminando las transacciones
    - No se podrá agrupar una secuencia de sentencias en una misma transacción.
    - Atomicidad limitada a cada sentencia por separado.
      - Bloqueos breves: imperceptibles.
- Resultado: Almacenes NoSQL.

# 4. Almacenes NoSQL

- Variantes de almacenes NoSQL:
  1. Almacenes clave-valor.
  2. Almacenes de documentos.
  3. Almacenes de registros extensibles.

# 4.1. Almacenes clave-valor

- Esquema compuesto por dos campos: clave y valor.
- No hay apenas soporte para distinguir atributos en el "valor".
- No hay forma de "interrogar" por atributos no primarios.
- Ejemplos: Dynamo, Voldemort, Riak…

# 4.2. Almacenes de documentos

- Esquema compuesto por objetos con un número variable de atributos.
- En algunos casos estos atributos pueden ser, a su vez, objetos.
- Lenguaje de interrogación basado en establecer restricciones sobre los valores de los atributos.
- Ejemplos: CouchDB, MongoDB, SimpleDB…

# 4.3. Almacenes de registros extensibles

- Esquemas formados por tablas que pueden tener un número variable de columnas.
  - En algunos casos se organizan en grupos de columnas.
- Las tablas pueden particionarse tanto vertical como horizontalmente.
  - Reparte responsabilidad entre múltiples nodos.
  - Equilibrado de la carga.
  - Mayor concurrencia.
  - ¡Fácilmente escalable sobre múltiples servidores!
- Ejemplos: Bigtable, PNUTs, Cassandra…

# Índice

# 5. Elasticidad

- Un sistema se considera elástico cuando:
  - Es escalable.
  - Es adaptable.
    - Asigna a cada aplicación la cantidad justa de recursos que necesite.
    - Esta adaptación es:
      - Dinámica: Depende de la carga que haya en cada momento.
      - Autónoma: El sistema administra sus recursos sin intervención humana.
- Definición:
  - "Elasticidad es el grado en que un sistema es capaz de adaptarse a cambios en su carga suministrando y reciclando los recursos de una manera autónoma, consiguiendo que en cada momento los recursos disponibles cubran la demanda existente con la mayor precisión posible".

# 5. Elasticidad

- La elasticidad es importante en los sistemas "cloud" modernos.
  - A la hora de ajustar el coste para el usuario.
  - A la hora de administrar los recursos del proveedor.
- Requiere:
  - Un sistema de monitorización:
    - De la carga soportada.
    - Del rendimiento obtenido.
  - Un sistema de actuación:
    - Para automatizar la reconfiguración de los servicios.
      - Para incorporar más nodos cuando la carga aumente.
      - Para liberar recursos cuando la carga disminuya.
    - En función del "*Service Level Agreement*" (SLA) establecido.
      - La reacción del sistema debe ser rápida, para no incumplir las condiciones del SLA.

# Índice

# 6. Contención y cuellos de botella

- En cualquier servicio distribuido habrá múltiples componentes.
- Su diseño debe ser cuidadoso para evitar la contención (bloqueo, saturación) en alguno de ellos.
  - Es decir, que alguno de los componentes se sature o bloquee a los demás, mientras los demás admitan cargas mayores.
- Causas de la contención:
  - Uso de algoritmos centralizados en algunas tareas "pesadas".
    - La centralización solo tiene sentido para reducir tráfico en casos de tareas "ligeras" o infrecuentes.
  - Uso de herramientas de sincronización.
    - Si hay recursos compartidos entre múltiples actividades, habrá una sección crítica y su protección conducirá a bloqueos.
  - Tráfico excesivo.
    - Una mala distribución de los recursos puede conducir a un incremento de las necesidades de comunicación remota.

# 6. Contención y cuellos de botella

- ¿Cómo evitar la contención?
  - Ante "centralización":
    - Adoptando una solución descentralizada, en caso de que la tarea a desarrollar sea "pesada".
  - En el acceso a recursos compartidos:
    - Serializando los accesos y adoptando un paradigma de programación asincrónica.
      - Si no hay competición por el uso de los recursos, resulta más fácil gestionar la carga.
      - El sistema resultante es más eficiente.
        - Menos cambios de contexto.
        - Menor carga para el sistema operativo y el middleware.
  - Por tráfico excesivo:
    - Replicar los recursos y mantenerlos consistentes.
    - Los accesos remotos se transforman en accesos locales.

# Índice

# Índice

# 7.1. El módulo "cluster" de NodeJS

- Los procesos en Node.js sólo tienen un hilo de ejecución.
- Si, por razones de escalabilidad, se necesita que un componente del sistema distribuido disponga de más instancias, no se podrán crear más hilos:
  - Habrá que crear más procesos, instancias del mismo componente
  - Si existen varios procesos, réplicas de un mismo componente, se podrá repartir el incremento de la carga de servicio entre ellos
- El módulo `cluster` de Node.js facilita:
  - La creación y gestión de un pool de trabajadores (procesos de Node)
  - El reparto equilibrado de la carga de servicio entre los procesos

# 7.1. El módulo "cluster" de NodeJS

- El módulo **`cluster`**:
  - Permite aprovechar los sistemas multiprocesador, mediante la ejecución de un cluster de procesos Node.
    - Para ello, reparte la carga de servicio entre los procesos que se ejecutarán en los distintos procesadores.
  - Permite crear procesos que comparten todos los puertos asociados al servicio que presten.
  - Incluye una clase **`worker`** que modela los procesos (trabajadores) del cluster.
    - Son supervisador y creados por un proceso "master".
  - Dispone de eventos ('`fork`', '`online`', '`listening`', '`disconnect`', '`exit`'…) que le permiten supervisar el estado de los procesos trabajadores (workers).
  - Usa IPC en la comunicación de los workers con el cluster master.

# 7.1. El módulo "cluster" de NodeJS

- Esquema básico de un cluster o pool de trabajadores:

```
var cluster = require('cluster');
var numCPUs = require('os').cpus().length;
var server = ... // the server which runs the workers
var port = ...   // the port where the server binds

if (cluster.isMaster) {  // code of the master one
   // fork: create workers
   for (var i=0; i < numCPUs; i++) cluster.fork();
   // listening death of workers
   cluster.on('exit', function(worker, code, signal) {
      console.log('worker', worker.process.pid, 'died');
   });
} else {  // code of any worker
   server.listen(port); // each worker runs the server
}
```

# 7.1. El módulo "cluster" de NodeJS

- Ejemplo: Código de un cluster de servidores http:

```
var cluster = require('cluster');
var http = require('http');
var numCPUs = require('os').cpus().length;

if (cluster.isMaster) {  // code of the master one
   for (var i=0; i < numCPUs; i++) cluster.fork();
   cluster.on('exit', function(worker, code, signal) {
      console.log('worker', worker.process.pid, 'died');
   });
} else {  // code of any worker
   http.createServer(function(req, res) {
      res.writeHead(200);
      res.end('hello world\n');
   }).listen(8000);
}
```

# 7.1. El módulo "cluster" de NodeJS

- Eventos del objeto `Cluster`:
  - '`fork`': cuando se crea un nuevo worker
  - '`online`': cuando se recibe un mensaje de un worker indicando que ha comenzado a ejecutarse
  - '`listening`': cuando un worker ejecuta un `listen()`
- Estos eventos pueden usarse para supervisar la actividad de los workers y asociarles timeouts. Por ejemplo:

```
var timeouts = [];
function errorMsg() { console.error('Something wrong...');}
cluster.on('fork', function(worker) {
   timeouts[worker.id] = setTimeout(errorMsg, 2000);
});
cluster.on('listening', function(worker, address) {
   clearTimeout(timeouts[worker.id]);
});
```

# 7.1. El módulo "cluster" de NodeJS

- Eventos del objeto **`Cluster`**:
  - '**`disconnect`**': cuando el canal IPC de un worker se desconecta (porque el worker termine, '`exit`', o sea eliminado, '`kill`', o se desconecte, '`disconnect`')
  - '**`exit`**': cuando un worker muere
- Estos eventos pueden usarse para detectar la inactividad de los workers y reiniciarlos, usando **`fork`**. Por ejemplo:

```
cluster.on('exit', function(worker, code, signal) {
   console.log('worker %d died (%s). restarting...',
               worker.process.pid, signal || code);
   cluster.fork();
});
```

# 7.1. El módulo "cluster" de NodeJS

- El objeto `Cluster` dispone de un objeto `cluster.workers`:
  - Es un **hash** que almacena los workers activos, indexados por su id.
  - El evento '`fork`' añade un worker a `cluster.workers`.
  - Los eventos '`disconnect`' y '`exit`' eliminan un worker del cluster.
- El cluster master puede enviar mensajes a un worker determinado o a todos los workers.

# 7.1. El módulo "cluster" de NodeJS

- Cada objeto **`worker`** (accesible mediante "*`cluster.worker`*") dispone de:
  - Atributos:
    - **`id`** (identificador único del worker en *`cluster.workers`*)
    - **`process`** (su proceso)
    - **`exitedAfterDisconnect`** (boolean que permite distinguir entre exit voluntario (true) o muerte causada por otro proceso (false))
  - Métodos, que se invocan mediante su atributo *`process`*, por ejemplo: *`process.send(…)`*:
    - **`send`** (envío de mensajes al master)
    - **`disconnect`**
    - **`kill`**
  - Eventos:
    - '**`message`**', '**`online`**', '**`listening`**', '**`disconnect`**', '**`exit`**', '**`error`**'

# 7.1. El módulo "cluster" de NodeJS

- Los mensajes entre master y workers (eventos '**message**') pueden usarse, por ejemplo, para contar las peticiones de servicio:

```
var cluster = require('cluster');
var http = require('http');
if (cluster.isMaster) {
  var numReqs = 0;
  setInterval(function(){ console.log("numReqs =", numReqs);}, 1000);
  function messageHandler(msg) {
    if (msg.cmd && msg.cmd == 'notifyRequest') numReqs++;
  }
  var numCPUs = require('os').cpus().length;
  for (var i=0; i < numCPUs; i++) cluster.fork();
  for (var i in cluster.workers)
    cluster.workers[i].on('message', messageHandler);
} else {
  http.Server(function(req, res) {
    res.writeHead(200); res.end('hello world\n');
    process.send({ cmd: 'notifyRequest' });
  }).listen(8000);
}
```

# Índice

# 7.2. Escalabilidad sobre múltiples máquinas

- El módulo cluster es adecuado para aprovechar los recursos multiprocesador en una sola máquina.
- Sin embargo, las peticiones de servicio pueden sobrepasar la capacidad de una máquina multiprocesador. Se hará necesario escalar el servicio sobre varias máquinas.
- Algunas soluciones:
  - node-http-proxy
  - HAProxy
  - nginx [engine x]

# 7.2. Escalabilidad sobre múltiples máquinas

- **node-http-proxy** (https://github.com/nodejitsu/node-http-proxy)
  - Es un servidor proxy de código abierto para aplicaciones Node
  - Permite configurar servidores http en diferentes máquinas
  - Permite balancear la carga (peticiones de servicio) entre los servidores
- Esquema básico del servidor proxy:

```
var proxyServer = require('http-proxy');
var port = ...
var servers = [{ host: ... , port: ... }, ... ,
               { host: ... , port: ... } ];

proxyServer.createServer(function (req, res, proxy) {
  var target = servers.shift();
  proxy.proxyRequest(req, res, target);
  servers.push(target);
}).listen(port);
```

# 7.2. Escalabilidad sobre múltiples máquinas

- **HAProxy** (http://www.haproxy.org/)
  - Servidor proxy (para aplicaciones TCP y HTTP), de código abierto (escrito en C)
  - Proporciona equilibrado de carga, alta disponibilidad y fiabilidad, y escalado sobre múltiples máquinas
  - Usado en websites como GitHub, Stack Overflow, Tumblr, Twitter…

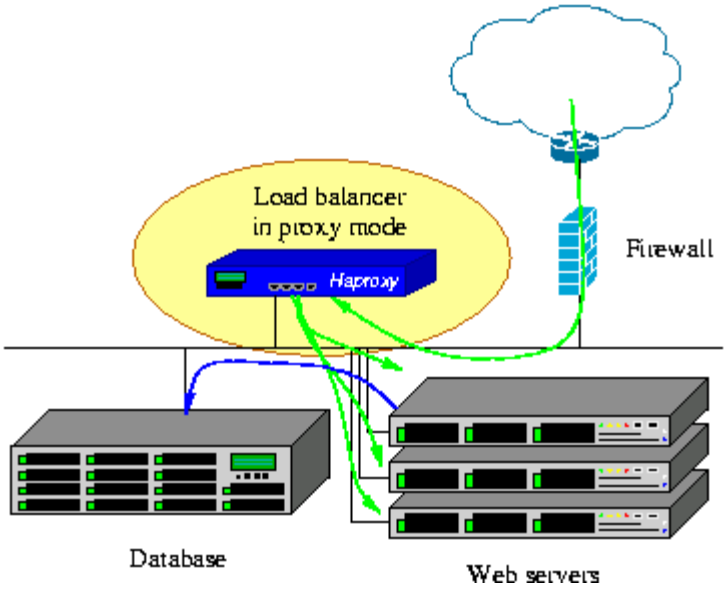

# 7.2. Escalabilidad sobre múltiples máquinas

- **HAProxy**. Ejemplo: Sea un servicio http de Node (*server.js*):

```
var http = require('http');
function serve(ip, port) {
  http.createServer(function (req, res) { ... }
}
serve('0.0.0.0', 9000);
serve('0.0.0.0', 9001);
serve('0.0.0.0', 9002);
```

- Un esquema básico de configuración de HAProxy para ese servicio:

```
frontend localnodes // where HAProxy listens to connections
  bind *:80
  mode http
  default_backend nodes
backend nodes // where HAProxy sends incoming connections
  mode http
  balance roundrobin
  ... // other configuration options of the backend
  server web01 127.0.0.1:9000 check
  server web02 127.0.0.1:9001 check
  server web03 127.0.0.1:9002 check
```

# 7.2. Escalabilidad sobre múltiples máquinas

- **nginx** (http://nginx.org/en/)
  - Servidor proxy inverso, de código abierto. Desarrollado por Igor Sysoev. Soportado comercialmente por Nginx, Inc.
  - Implantado inicialmente en websites de Rusia. Actualmente, se ha extendido por todo el mundo y lo usan más del 20% de los websites de mayor carga.

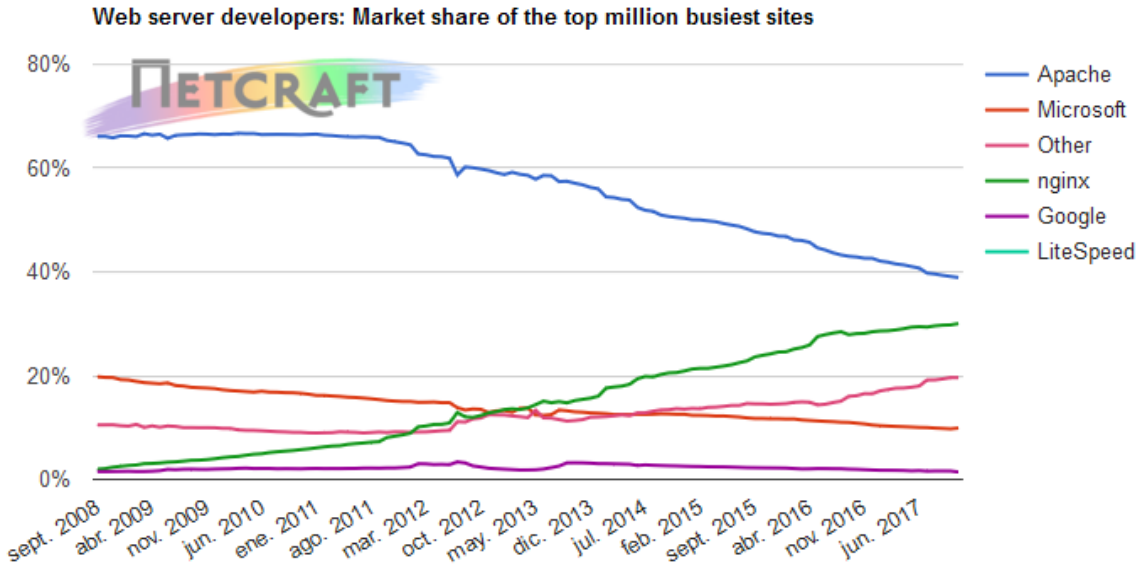

# 7.2. Escalabilidad sobre múltiples máquinas

- **nginx** (http://nginx.org/en/)
  - Es un servidor proxy inverso (para aplicaciones HTTP y de email)
  - Permite configurar servidores http en diferentes máquinas y balancear la carga (peticiones de servicio) entre los servidores
- Esquema básico de configuración (load balancing, round robin):

```
http {
  upstream myapp1 {
    server srv1.example.com;
    server srv2.example.com;
    server srv3.example.com;
  }
  server {
    listen 80;
    location / { proxy_pass http://myapp1; }
  }
}
```

# Índice

# 7.3. MongoDB

- MongoDB es "almacén de documentos" escalable.
- Por ser un almacén de documentos:
  - Una base de datos es un conjunto de colecciones.
    - Colección = Tabla.
  - Cada colección es un conjunto de objetos estructurados.
    - Cada objeto / documento tiene un identificador y múltiples atributos.
      - El identificador es equivalente a la clave primaria en el modelo relacional.
    - Los atributos, a su vez, pueden estructurarse: tipos simples, vectores, objetos (con atributos)…
      - Cada atributo puede verse como un par <clave, valor>.
        - Donde "clave" es el nombre del atributo.
    - No se exige que todos los documentos de una misma colección tengan idéntica estructura.
      - Esquema flexible.

# 7.3.1. Componentes en MongoDB

- Para interactuar con un SGBD MongoDB se puede utilizar el shell "mongo".
  - Proporciona una interfaz JavaScript para acceder a los servidores MongoDB.
  - Su orden "help" proporciona una primera descripción básica de todas las órdenes que admite.
  - A su vez:
    - "db.help()" describe todos los métodos que se pueden utilizar sobre una BD.
    - "db.colec.help()" describe todos los métodos que se pueden utilizar sobre una colección "colec" de la BD.
- En la configuración más sencilla, "mongo" interactuará con un servidor "mongod".
  - El servidor "mongod" debe ser iniciado en primer lugar.

# 7.3.1. Componentes en MongoDB

- Configuración más sencilla:
  - Se puede utilizar una sola máquina.
  - Habrá un servidor "mongod" para gestionar la BD.
  - Se utilizará un *shell* "mongo" para interactuar con "mongod" y acceder así a la BD.
    - O bien un programa escrito en alguno de los lenguajes para los que haya algún "driver" de MongoDB.

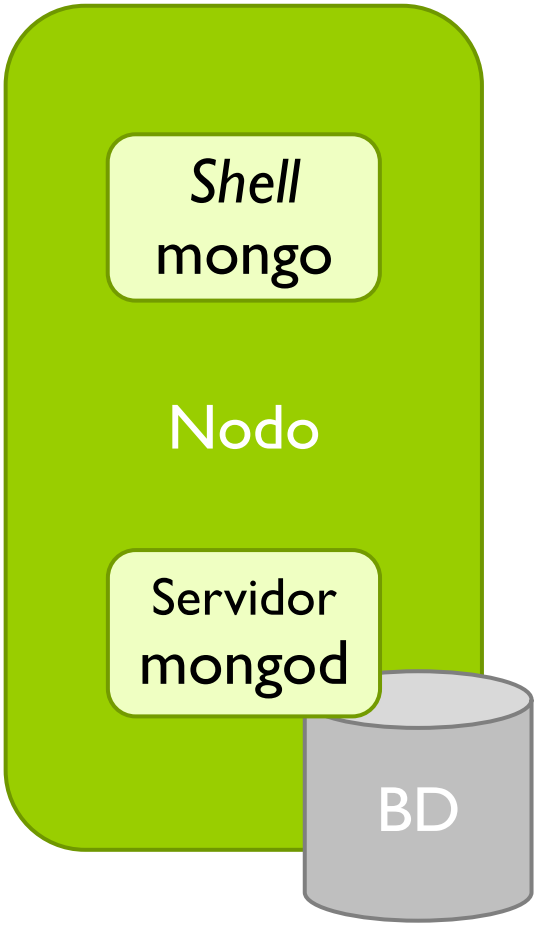

# 7.3.1. Componentes en MongoDB

- Configuraciones más complejas en sistemas escalables.
- Se utiliza particionado horizontal ("*sharding*").

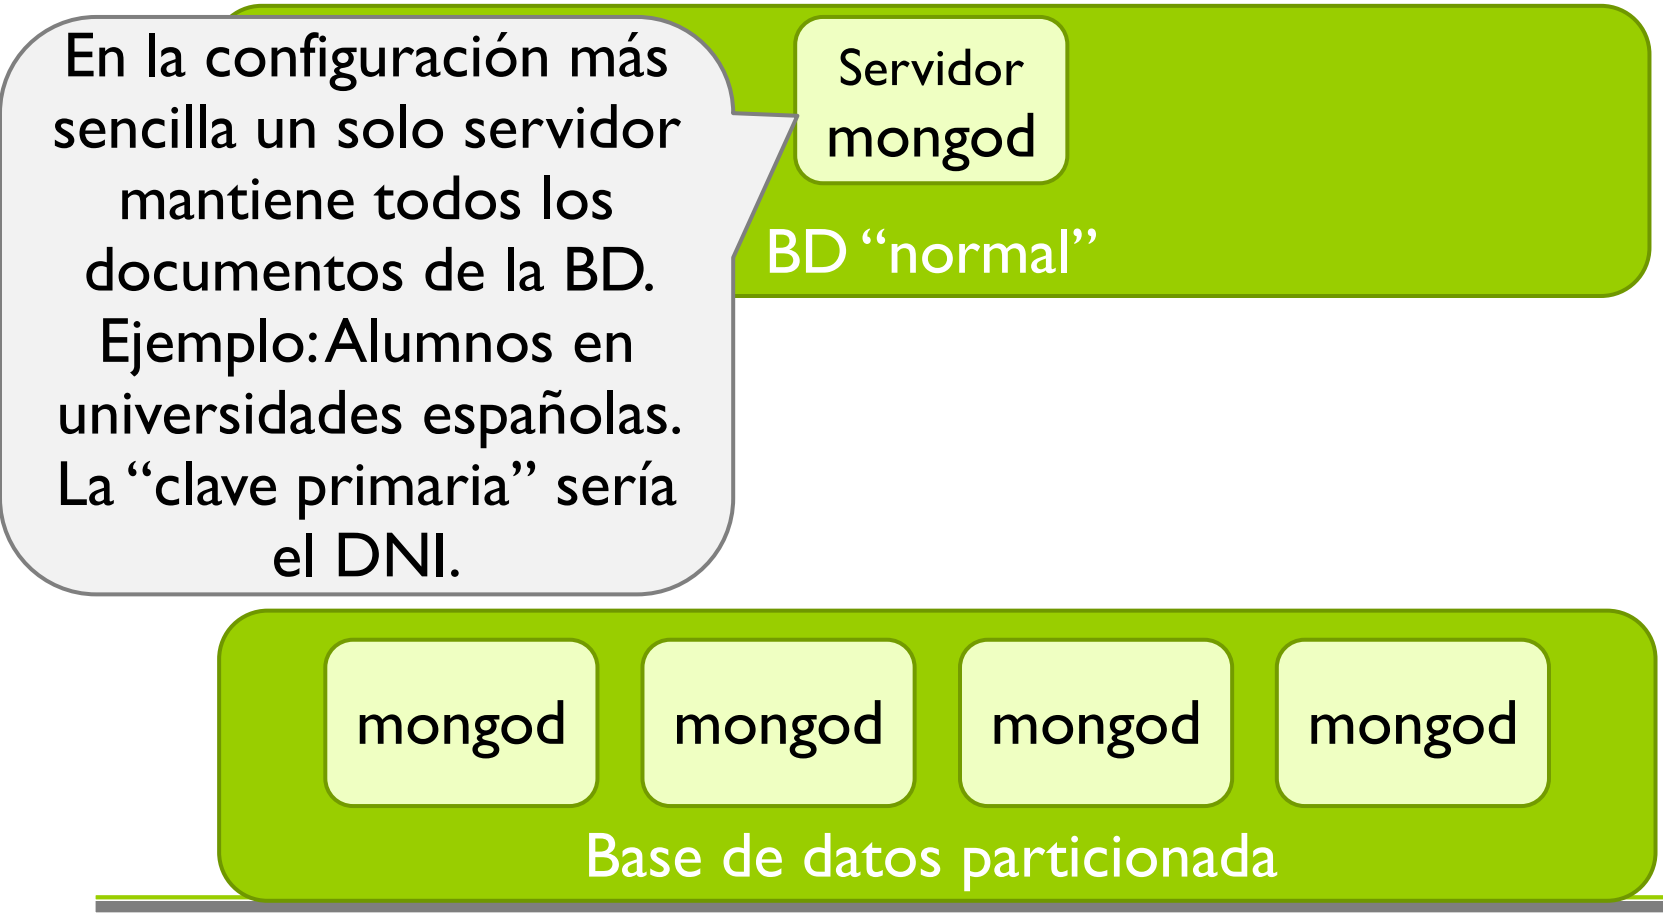

# 7.3.1. Componentes en MongoDB

- Configuraciones más complejas en sistemas escalables.
- Se utiliza particionado horizontal ("*sharding*").

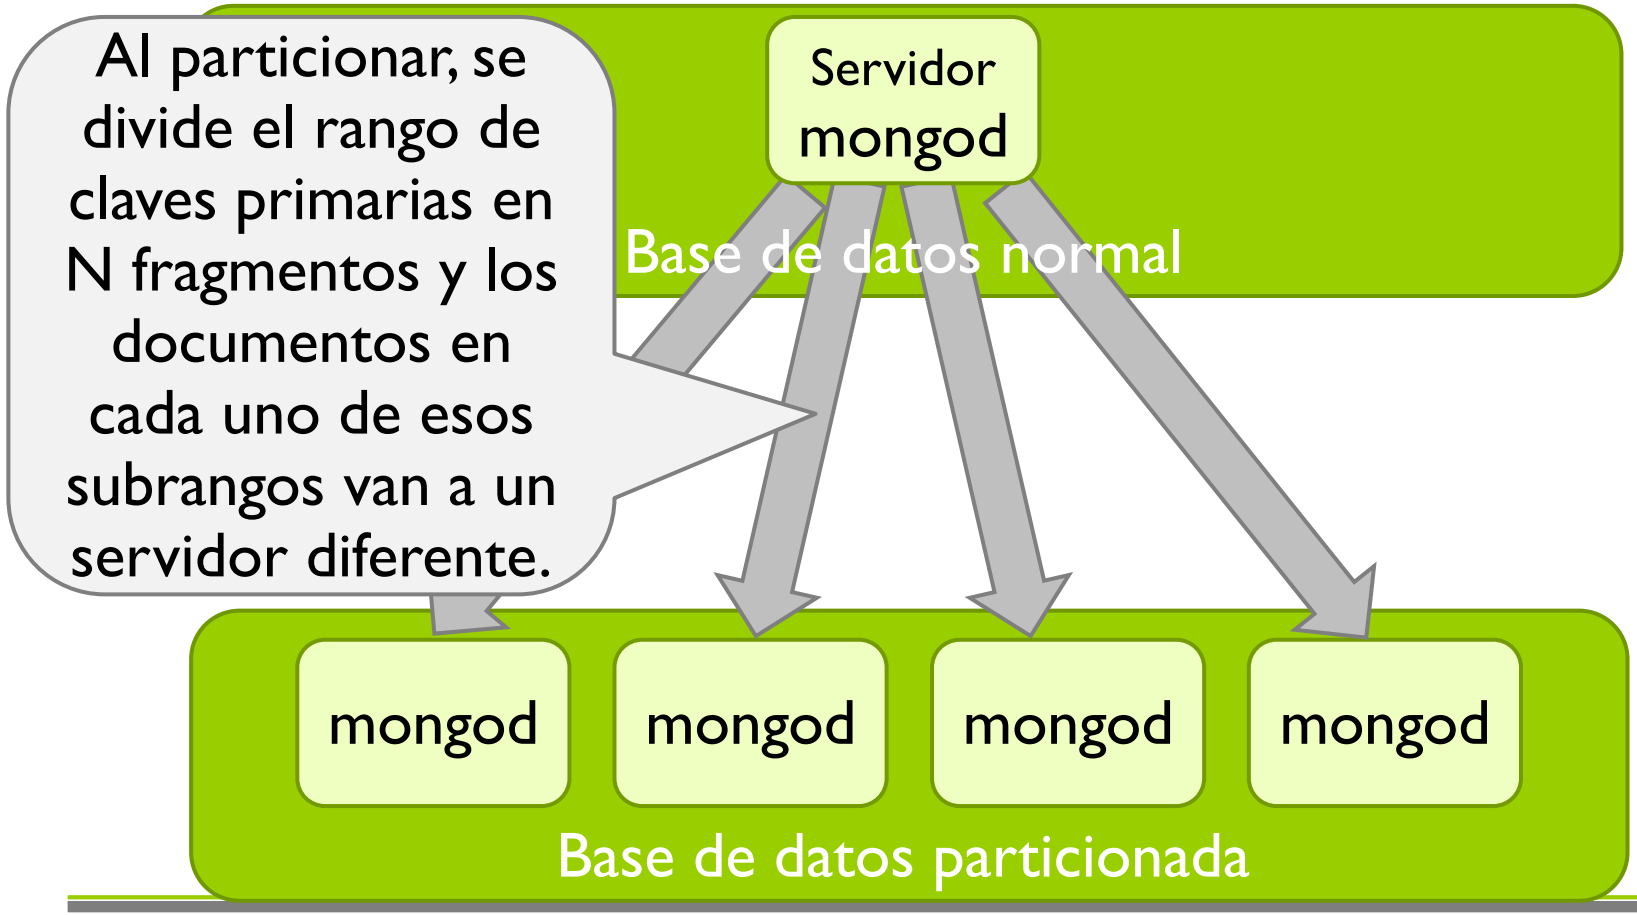

# 7.3.1. Componentes en MongoDB

- Configuraciones más complejas en sistemas escalables.
- Se utiliza particionado horizontal ("*sharding*").

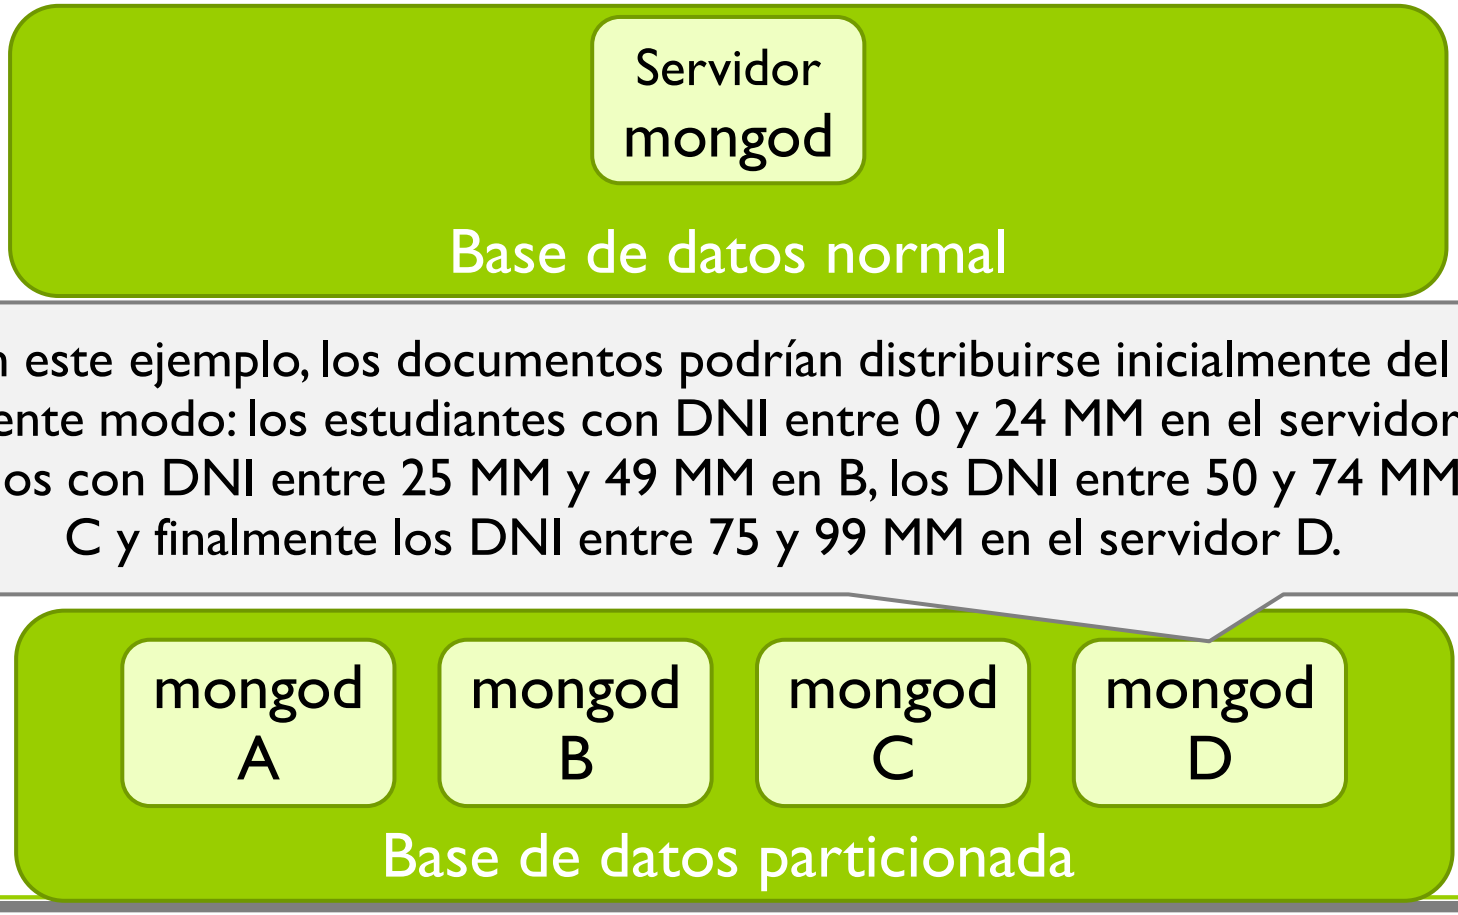

# 7.3.1. Componentes en MongoDB

- Cuando se acceda a una BD grande, habrá que utilizar tres tipos de "servidores" (cada servidor en un nodo) [2]:
  - Procesos "mongod"
    - Cada uno mantiene un subconjunto de filas de la base de datos.
      - Llamaremos "partición" ("*shard*") a cada subconjunto.
    - Para mejorar la escalabilidad, se utiliza particionado horizontal.
    - Cada "partición" puede replicarse.
  - Procesos "mongos"
    - En caso de utilizar particionado, son los procesos que actúan como interfaz con la aplicación cliente.
      - Encaminan las peticiones hacia el proceso "mongod" apropiado: "*routers*".
    - Consultan a los servidores de configuración para saber en qué "mongod" se encuentran las filas a utilizar.
      - Redirigen posteriormente la petición a esos procesos.
  - Servidores de configuración
    - Guardan los metadatos de la BD.
    - Saben qué filas forman cada partición y en qué nodo se ubica cada partición.
    - Forman un "conjunto de réplicas"; es decir, usan el protocolo de replicación normal de MongoDB.

# 7.3.1. Componentes en MongoDB

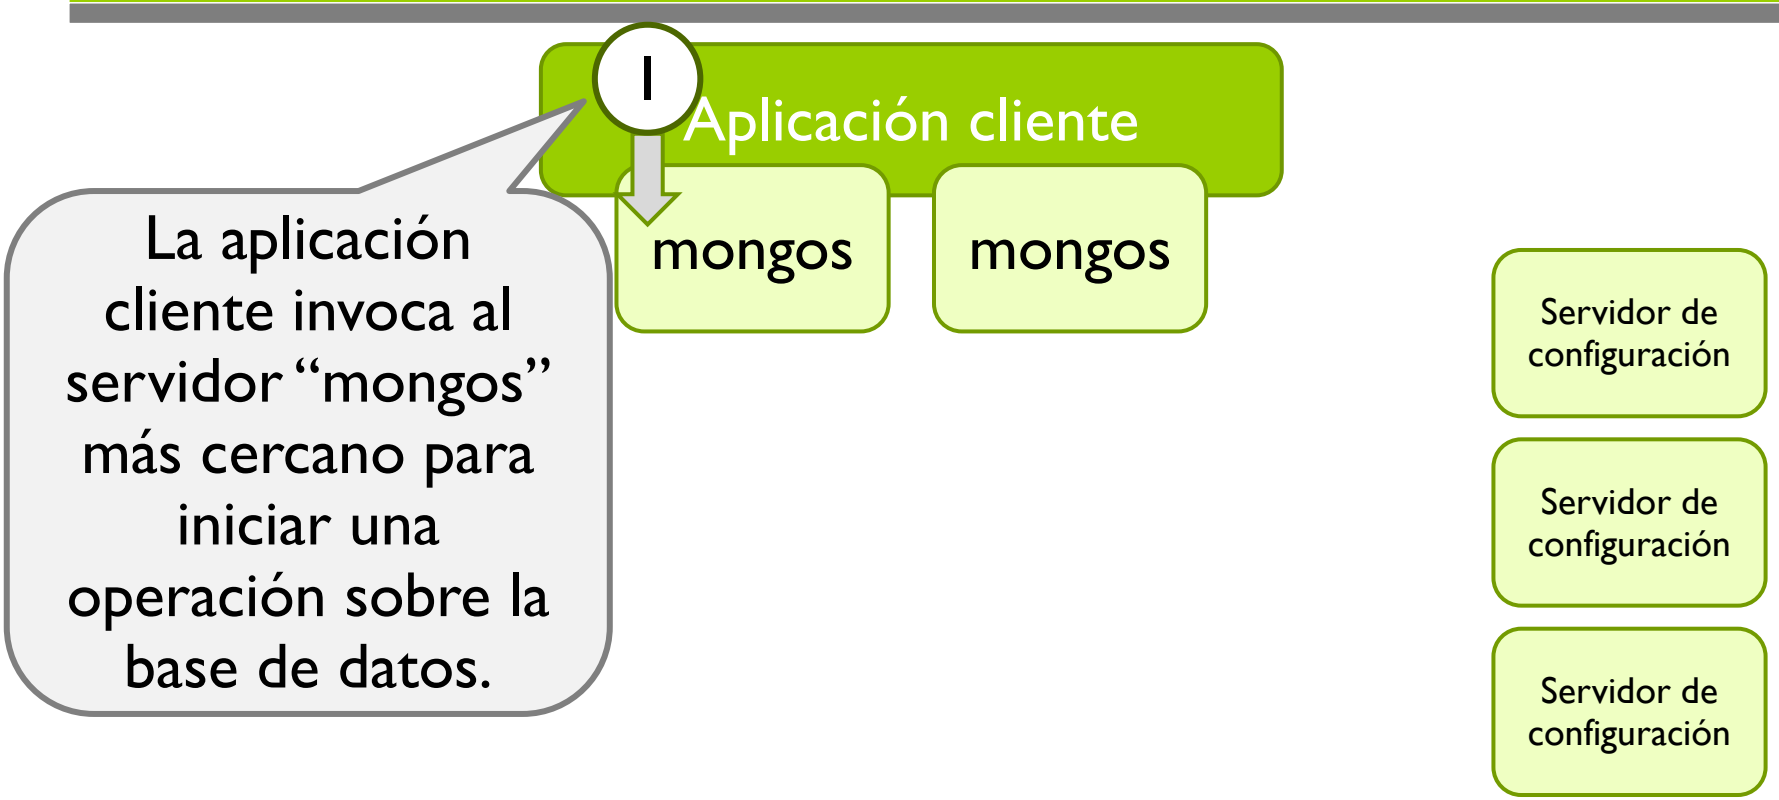

# 7.3.1. Componentes en MongoDB

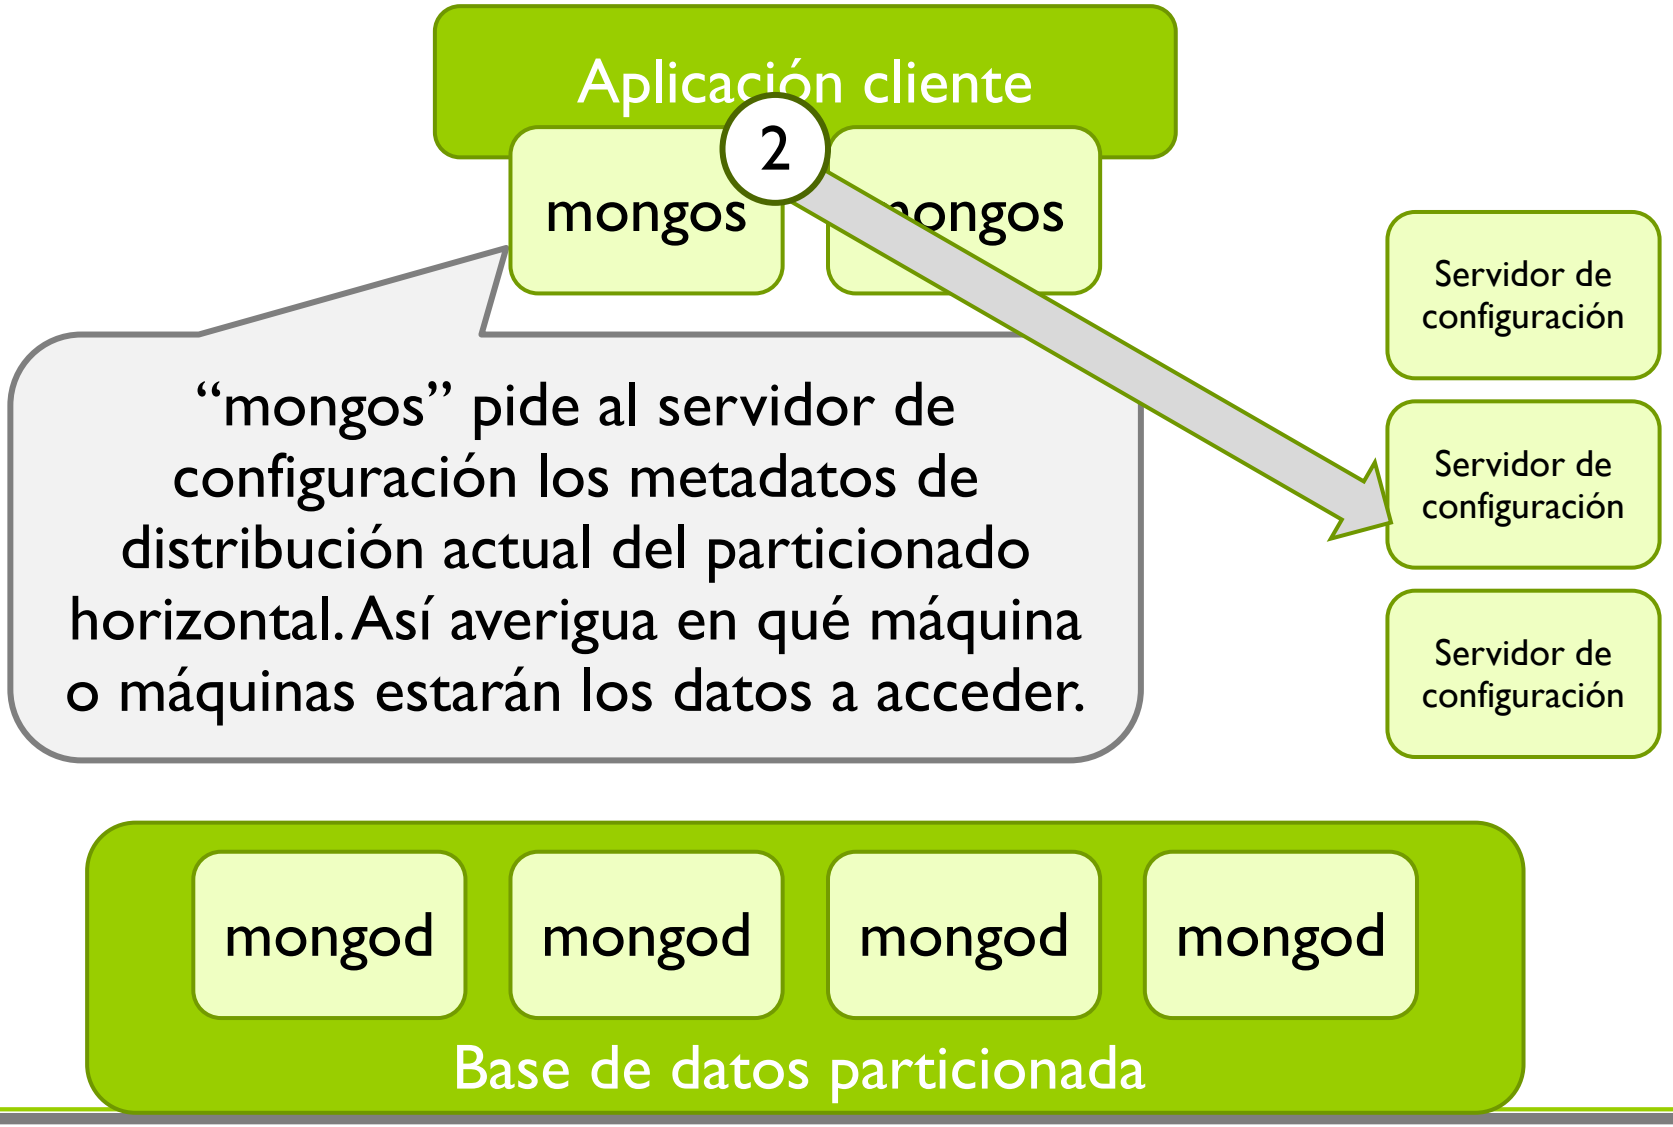

# 7.3.1. Componentes en MongoDB

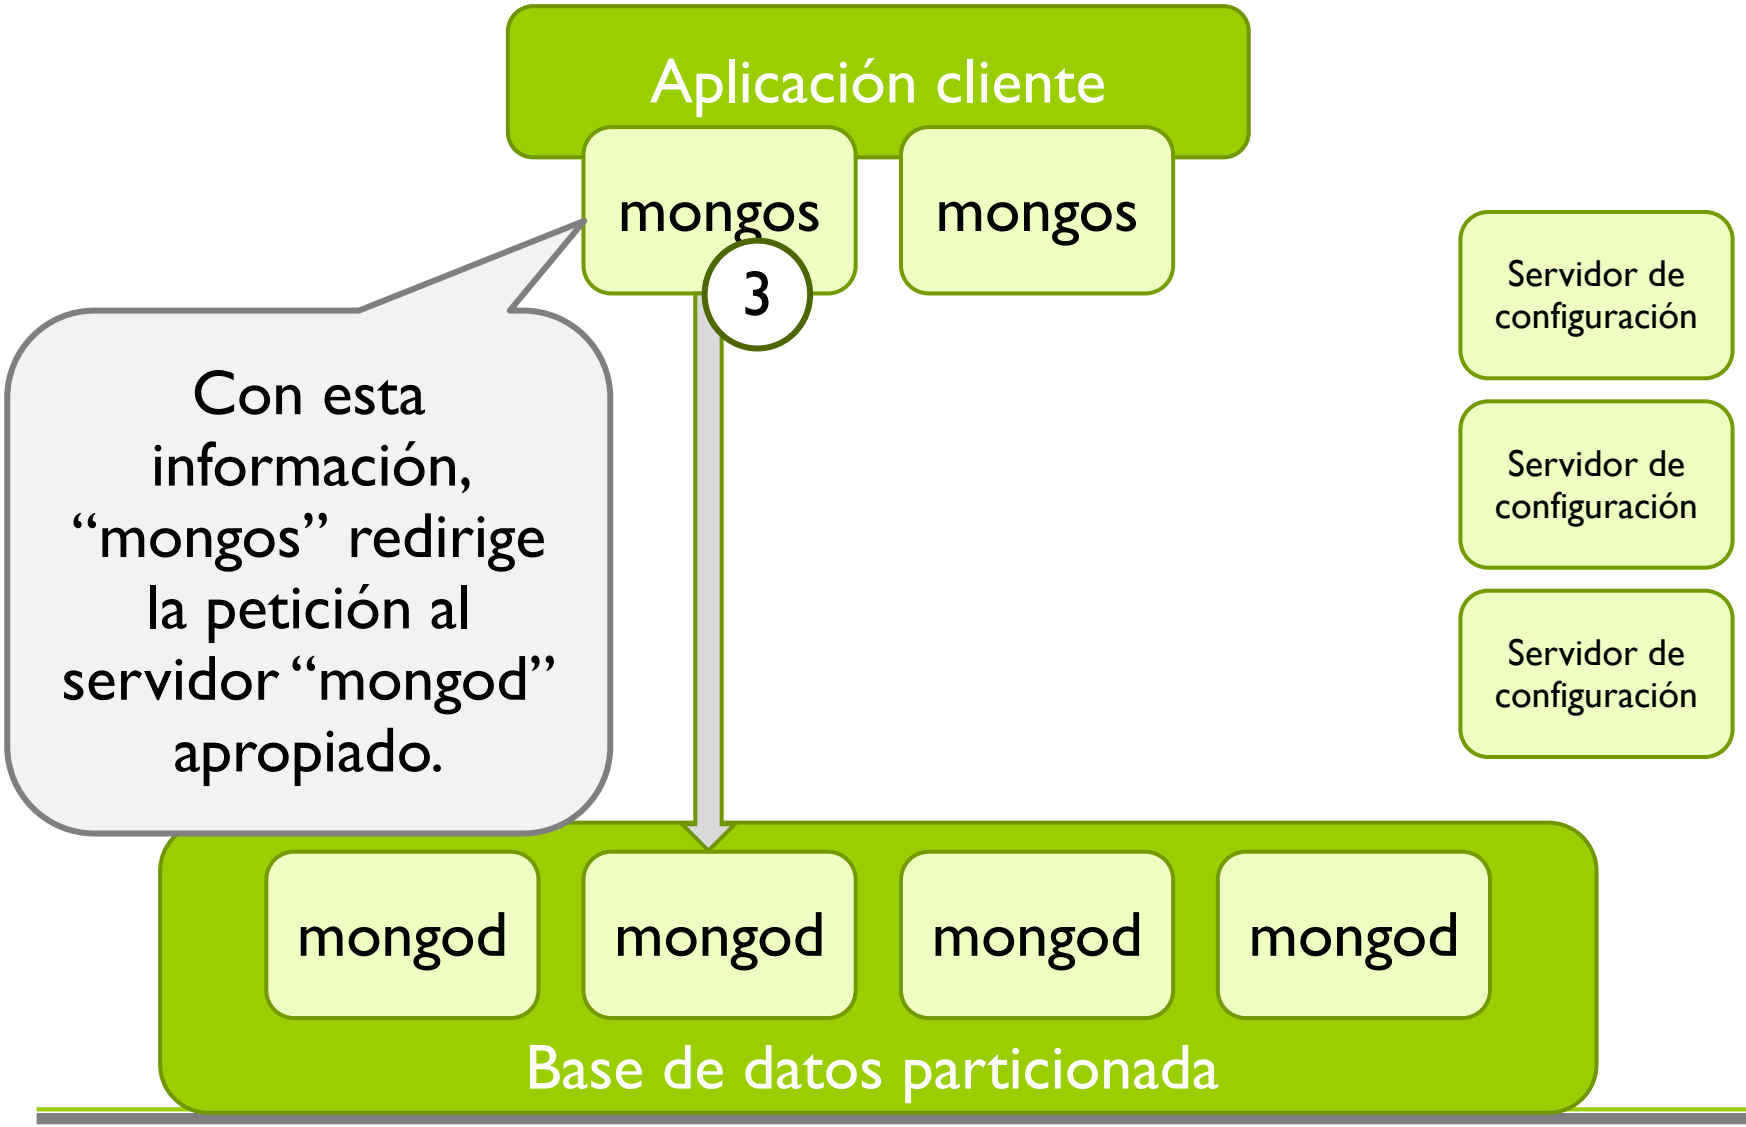

# 7.3.1. Componentes en MongoDB

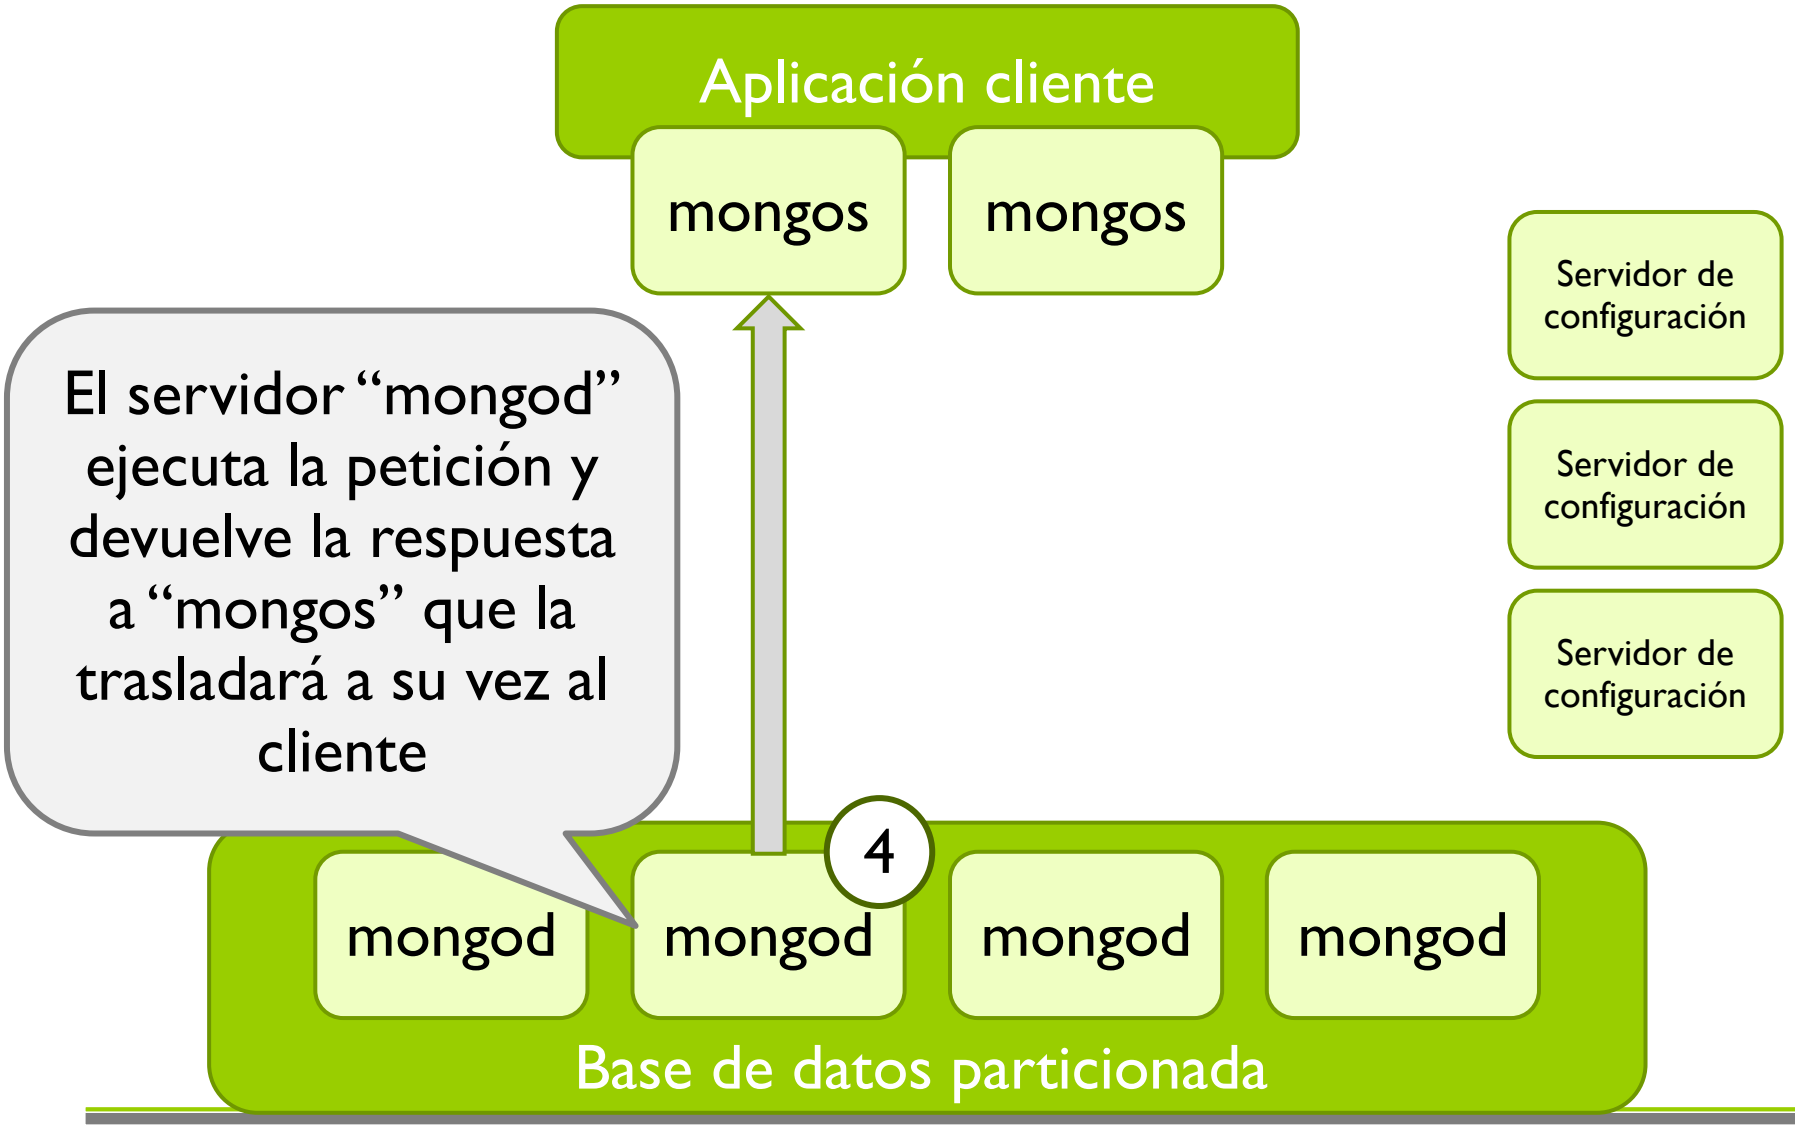

# 7.3.2. Servidor "mongod"

- Es el servidor del SGBD.
- También llamado "*shard server*" en caso de particionado de la BD.
  - "*Shard*" = Subconjunto de la BD mantenido por un mismo servidor.
- En caso de que no se use particionado ni replicación, basta con un "mongod" para acceder a la BD.
- Habrá que particionar la BD cuando:
  - Un solo "mongod" no soporte toda la carga que introducen los usuarios, o…
  - Los datos guardados en la BD llenen el disco de la máquina en que se ejecute "mongod".

# 7.3.2. Servidor "mongod"

- Si se particiona la base:
  - El subconjunto ("*shard*") de cada servidor se divide en fragmentos ("*chunks*").
  - Cada fragmento ("*chunk*") no podrá superar los 64 MB.
    - Cuando eso sucede, el fragmento se divide en dos.
  - Un proceso equilibrador de carga monitoriza cuántos fragmentos tiene cada servidor "mongod".
    - Si el número es desigual, se migra al menos un fragmento del servidor que tenga más al que tenga menos.
      - Hasta que el número de fragmentos se equilibre.
    - Para migrar un fragmento:
      - Se inicia la copia a su servidor destino.
      - Mientras dure la copia, todas los accesos se dirigen al servidor origen.
      - Cuando la copia finaliza:
        1. Se guarda en los servidores de configuración que la migración terminó.
        2. Se borra el fragmento del servidor origen.

# 7.3.2. Servidor "mongod"

- Para evitar inconsistencias, se utiliza "*journaling*":
  - Cada modificación se escribe primero en un "*journal*".
    - Se anota el tipo de operación, los datos que modificará y su resultado.
    - Posteriormente se aplica sobre la BD.
  - Si ocurre algún fallo durante la modificación:
    - Si el fallo se da antes de terminar, el cliente no obtiene respuesta.
    - Al reanudar la ejecución, se examina el fichero "*journal*" y se comprueba si sus operaciones fueron aplicadas sobre la base.
      - Toda operación no finalizada se aplica ahora sobre la BD.
  - Ventajas:
    - Se evita la corrupción de los datos de la BD en caso de fallo.
      - No habrá escrituras incompletas.
    - Se acelera la reanudación del nodo.

# 7.3.3. Servidor "mongos"

- Debe ser el único tipo de servidor directamente accesible por parte de las aplicaciones y usuarios en caso de particionar la BD.
- "mongos" no mantiene ningún elemento de la BD.
  - Los elementos / datos están almacenados en los "mongod".
- Actúa únicamente como "encaminador" de las peticiones.
- La información sobre el "reparto" efectuado debe obtenerse desde los servidores de configuración.
  - Una vez obtenida se mantiene en una caché local.
  - La caché se refrescará cuando su información no consiga encontrar los documentos solicitados.
  - El reparto se modifica cuando se migran fragmentos para equilibrar la carga.

# 7.3.4. Servidor de configuración

- Son procesos "mongod".
  - Pero no mantienen datos de la BD.
  - Mantienen los metadatos: reparto de los "*shards*".
- Otras características:
  - Están replicados.
    - Ubicados en máquinas diferentes.
  - Esto permite agilizar su recuperación cuando uno de ellos falle.
    - Los otros dos seguirán siendo "mayoría".
  - Todas las modificaciones sobre los metadatos se aplican mediante un protocolo de "commit" en dos fases.
    - Asegura consistencia fuerte.
    - Pero es un protocolo pesado que requiere un alto número de mensajes.

# 7.3.5. Replicación

- Se pueden replicar los servidores "mongod" para:
  - Mejorar la disponibilidad
    - Se soportarán los fallos de manera transparente
  - Incrementar el rendimiento
    - Las consultas pueden repartirse entre las réplicas
      - Con ello se incrementa la escalabilidad
- Se adopta un modelo de replicación pasivo
  - La réplica primaria es la única que puede ejecutar inserciones, modificaciones y borrados
    - Posteriormente propaga el resultado de estas acciones a las demás réplicas, para que también los apliquen
    - La propagación es asincrónica
  - Las réplicas secundarias también pueden ejecutar consultas
    - Sin que intervenga la réplica primaria
- Transparencia: Cualquier servidor "mongod" puede ser reemplazado por un "*replica set*" (conjunto de réplicas bajo el modelo pasivo)
  - Interesante para el "*sharding*": Cada partición puede ser gestionada por un "*replica set*" diferente.

# 7.3.5. Replicación

- Roles
  - Se distinguen tres posibles roles
    - Primario: única réplica que atenderá las operaciones que impliquen escritura
      - Normalmente también atiende las consultas
    - Secundario: resto de réplicas que mantienen copia de los datos
      - Se admite que gestionen consultas
    - Árbitro: réplica lógica que no mantiene datos
      - Participa en las votaciones para elegir un primario en caso de fallo
  - Un conjunto de réplicas no podrá tener más de 50 unidades
    - El número de "votantes" en caso de fallo está limitado a 7
      - El resto de réplicas serán "secundarios sin voto".

# 7.3.5. Replicación

- Gestión de fallos
  - No se toleran las situaciones de particionado
  - En caso de fallo, MongoDB solo podrá continuar si hay una mayoría de réplicas correctas
    - Correcta -> Aquella que siga activa y pueda comunicarse con las demás activas en un subgrupo mayoritario
    - Se recomienda:
      - Tener un número impar de réplicas
        - P.ej., 3 réplicas soportan 1 fallo, 5 réplicas soportan 2 fallos, 7 réplicas soportan 3 fallos...
      - Si el número debiera ser par, se añadirá una réplica "árbitro"
        - En caso de partición, permite elegir qué subgrupo será mayoritario
          - P.ej., con 6 réplicas y 1 árbitro... una partición podría dejar aislados dos subgrupos:
            - A: 3 réplicas
            - B: 3 réplicas + árbitro
            - Sólo podrá continuar B, porque tiene 4 de las 7 réplicas (mayoría)
  - La detección del fallo y la sustitución del primario son gestionadas automáticamente por MongoDB
    - Ni el programador ni el usuario deben preocuparse

# 7.3.5. Replicación

- Sincronía en las modificaciones: "*write concern*"
  - Las operaciones de inserción, modificación y borrado admiten una opción "w" ("*write concern*"):
    - Especifica cuántas réplicas deben confirmar la realización de la escritura para retornar el control al invocador
    - Por omisión, su valor es 1
      - Si fuera -1 o 0, asincronía total
        - El valor -1 se despreocupa completamente.
        - El valor 0 reporta, al menos, si ha habido errores en la comunicación con los servidores
        - No se asegura que el primario haya completado la escritura: persistencia no garantizada
        - Excesivamente peligroso en caso de fallo
      - Otras opciones:
        - 'majority':
          - Será 1 cuando no haya replicación
          - Será una mayoría de réplicas con derecho a voto en caso de replicación
          - ¡Es el valor recomendable!!
        - Cualquier número concreto
          - Puede plantear problemas en caso de fallos múltiples
          - Se debe conocer el número inicial de réplicas para fijar un número razonable ¡Pérdida de transparencia!!!
          - Problemático: si no hay suficientes réplicas, "colgaremos" la conexión

# 7.3.5. Replicación

- Como complemento de la replicación, se puede utilizar un **reparto horizontal** de la información entre un grupo de servidores
  - También conocido como:
    - "*Sharding*"
    - Particionado horizontal
  - Cada servidor recibe un subconjunto (o "*shard*") de la colección repartida
    - A su vez, el servidor responsable de un *shard* puede ser reemplazado por un *replica set*.
- Objetivo:
  - Repartir mejor la carga entre servidores
  - Incrementar la capacidad de servicio concurrente
    - Con mínima contención
  - Escalabilidad

# Índice

# 8. Resultados de aprendizaje

- Al finalizar este tema, el alumno debe ser capaz de:
  - Conocer el "Teorema CAP" y sus implicaciones en el diseño de servicios distribuidos escalables
  - Identificar los mecanismos básicos para conseguir escalabilidad
    - Consistencia relajada
    - Replicación multi-máster
    - Distribución de datos
  - Identificar las claves para tener un sistema distribuido elástico.
  - Conocer los principios de diseño para evitar la contención en los sistemas distribuidos escalables.

# Índice

# 9. Bibliografía


- Wilson, Jim R., *Node.js the Right Way*. Ed. Jacquelyn Carter, Col. The Pragmatic Bookshelf, 2013.
- http://nodejs.org/api/cluster.html (Node.js v0.10.33 Manual & Documentation)
- Ihrig, C., *Scaling Node.js Applications* (http://cjihrig.com/blog/scaling-node-js-applications/), 2013
- Cirkel, K., *Load balancing Node.js* (http://blog.keithcirkel.co.uk/load-balancing-node-js/), 2014
- Robbins, C., *node-http-proxy* (https://github.com/nodejitsu/node-http-proxy)
- Tarreau, W., *HAProxy* (http://www.haproxy.org/) (http://en.wikipedia.org/wiki/HAProxy)
- Sysoev, I., *nginx* (http://nginx.org/en/) (http://en.wikipedia.org/wiki/Nginx)